

Resumo Acadêmico de Tópicos CE308 – Teoria da Probabilidade 2

Baseado na Lista 2 do Prof. Benito Olivares Aguilera

Outubro de 2025

Este resumo expande os conceitos de **Estatísticas de Ordem** e **Distribuição Condicional**, focando nas propriedades formais e estratégias de solução relevantes para a lista.

1 Distribuição das Estatísticas de Ordem

Sejam $X_1, X_2, \dots, X_n$ uma amostra aleatória i.i.d. (independentes e identicamente distribuídas) de uma população com f.d.p. (função de densidade de probabilidade) $f_X(x)$ e F.d.a. (função de distribuição acumulada) $F_X(x)$.

As estatísticas de ordem são as variáveis aleatórias ordenadas:

$$Y_1 \leq Y_2 \leq \dots \leq Y_n$$

Onde $Y_1 = \min(X_1, \dots, X_n)$ e $Y_n = \max(X_1, \dots, X_n)$.

1.1 Distribuições Marginais (Mínimo, Máximo e k-ésima)

Macete Computacional 1. Para o **Mínimo** (Y_1), use o evento complementar $P(Y_1 > y)$. Para o **Máximo** (Y_n), use a definição direta $P(Y_n \leq y)$.

- **Mínimo** (Y_1): (Relevante para Q1, Q2, Q4)

$$\begin{aligned} F_{Y_1}(y) &= P(Y_1 \leq y) = 1 - P(Y_1 > y) \\ &= 1 - P(X_1 > y, \dots, X_n > y) \\ \text{(i.i.d.)} \quad &= 1 - \prod_{i=1}^n P(X_i > y) = 1 - [1 - \mathbf{F}_{\mathbf{X}}(\mathbf{y})]^n \end{aligned}$$

A f.d.p. é obtida pela derivação:

$$f_{Y_1}(y) = \frac{d}{dy} F_{Y_1}(y) = n[1 - \mathbf{F}_{\mathbf{X}}(\mathbf{y})]^{n-1} \mathbf{f}_{\mathbf{X}}(\mathbf{y})$$

- **Máximo** (Y_n): (Relevante para Q1, Q3)

$$\begin{aligned} F_{Y_n}(y) &= P(Y_n \leq y) = P(X_1 \leq y, \dots, X_n \leq y) \\ \text{(i.i.d.)} \quad &= \prod_{i=1}^n P(X_i \leq y) = [\mathbf{F}_{\mathbf{X}}(\mathbf{y})]^n \end{aligned}$$

A f.d.p. é obtida pela derivação:

$$f_{Y_n}(y) = \frac{d}{dy} F_{Y_n}(y) = \mathbf{n}[\mathbf{F}_X(y)]^{\mathbf{n}-1} \mathbf{f}_X(y)$$

- **k-ésima Estatística (Y_k):** (Teoria geral) A f.d.p. geral é derivada usando um argumento binomial (quantos X_i são $\leq y$):

$$f_{Y_k}(y) = \frac{n!}{(k-1)!(n-k)!} [F_X(y)]^{k-1} [1 - F_X(y)]^{n-k} f_X(y)$$

1.2 Distribuições Conjuntas

- **Conjunta de Y_1 e Y_n :** (Relevante para Q3) Para $y_1 < y_n$, a f.d.p. conjunta é:

$$f_{Y_1, Y_n}(y_1, y_n) = \mathbf{n}(\mathbf{n} - 1) [\mathbf{F}_X(y_n) - \mathbf{F}_X(y_1)]^{\mathbf{n}-2} \mathbf{f}_X(y_1) \mathbf{f}_X(y_n)$$

(O termo $[F_X(y_n) - F_X(y_1)]$ é a probabilidade de uma v.a. cair *entre* y_1 e y_n).

- **Conjunta de todas as $Y_1, \dots, Y_n$:** Para $y_1 < y_2 < \dots < y_n$:

$$f_{Y_1, \dots, Y_n}(y_1, \dots, y_n) = \mathbf{n}! \mathbf{f}_X(y_1) \mathbf{f}_X(y_2) \cdots \mathbf{f}_X(y_n)$$

(O $n!$ vem das $n!$ permutações possíveis da amostra original $X_1, \dots, X_n$).

1.3 Casos Notáveis e Propriedades (Macetes)

Propriedade 1 (Caso Exponencial - Q2, Q4). Se $X_i \sim \text{Exp}(\lambda_i)$ (não necessariamente i.i.d.), então o mínimo (tempo da primeira falha) também é exponencial:

$$Y_1 = \min(X_1, \dots, X_n) \sim \text{Exp}\left(\sum_{i=1}^n \lambda_i\right)$$

Isto é fundamental em análise de sobrevivência para "riscos concorrentes". Se as X_i são i.i.d. $\text{Exp}(\lambda)$, então $Y_1 \sim \text{Exp}(n\lambda)$.

Propriedade 2 (Caso Uniforme - Q3). Se $X_i \sim U(0, 1)$, então $F_X(x) = x$ e $f_X(x) = 1$ para $x \in (0, 1)$. As fórmulas se simplificam drasticamente.

- $f_{Y_k}(y) = \frac{n!}{(k-1)!(n-k)!} y^{k-1} (1-y)^{n-k} \sim \text{Beta}(\mathbf{k}, \mathbf{n} - \mathbf{k} + 1)$.
- $f_{Y_1, Y_n}(y_1, y_n) = n(n-1)(y_n - y_1)^{n-2}$ para $0 < y_1 < y_n < 1$.

Para $U(a, b)$, use a transformação linear $X = a + (b-a)U$ onde $U \sim U(0, 1)$.

Macete Computacional 2 (Cálculo de Covariância - Q3c). Para calcular $\text{Cov}(Y_1, Y_n)$, você precisa de $E[Y_1 Y_n]$, $E[Y_1]$ e $E[Y_n]$.

$$E[Y_1 Y_n] = \int_a^b \int_{y_1}^b y_1 y_n f_{Y_1, Y_n}(y_1, y_n) dy_n dy_1$$

$$E[Y_k] = \int_a^b y \cdot f_{Y_k}(y) dy$$

Usar a distribuição Beta para o caso $U(0, 1)$ é muito mais rápido, pois $E[Y_k] = \frac{k}{n+1}$.

2 Distribuição e Esperança Condicional

Este tópico trata de como a informação sobre uma v.a. X altera nosso conhecimento sobre Y .

2.1 Definições Formais

Definição 1 (Distribuição Condicional). *Sejam (X, Y) v.a. contínuas com densidade conjunta $f(x, y)$ e marginais $f_X(x)$ e $f_Y(y)$.*

- **Marginal de X :** $f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$
- **Condicional de Y dado X :** $f(y|x) = \frac{f(x, y)}{f_X(x)}$, definida para $f_X(x) > 0$.

(Análogo para o caso discreto $p(y|x) = p(x, y)/p_X(x)$ - Q10, Q13, Q14).

Macete Computacional 3 (Modelo Hierárquico - Q9, Q12, Q18, Q20). *Muitos problemas (especialmente Bayesianos) são definidos em etapas:*

1. X é sorteado de $f_X(x)$ (distribuição "a priori").
2. Y é sorteado de $f(y|x)$ (distribuição "verossimilhança").

Para resolver, use as "leis" na ordem inversa:

- **Achar Conjunta:** $f(x, y) = f(y|x)f_X(x)$
- **Achar Marginal de Y :** $f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx = \int f(y|x)f_X(x) dx$
- **Achar $f(x|y)$ (Regra de Bayes):** $f(x|y) = \frac{f(x, y)}{f_Y(y)} = \frac{f(y|x)f_X(x)}{\int f(y|u)f_X(u) du}$

2.2 Esperança Condicional

Definição 2 (Esperança Condicional). 1. $E[Y|X = x]$ é um **número** (ou função de x), calculado como a esperança de Y usando a densidade $f(y|x)$:

$$E[Y|X = x] := \int_{-\infty}^{\infty} y \cdot f(y|x) dy$$

2. $E[Y|X]$ é uma **Variável Aleatória**. É a função $g(x) = E[Y|X = x]$ aplicada à v.a. X , ou seja, $g(X)$.

Formalmente, $E[Y|X]$ é a única v.a. $\sigma(X)$ -mensurável que satisfaz $E[E[Y|X] \cdot \mathbb{I}(X \in A)] = E[Y \cdot \mathbb{I}(X \in A)]$ para todo conjunto A .

2.3 Propriedades Fundamentais da Esperança Condicional

Propriedade 3 (Linearidade). $E[aY + bZ|X] = aE[Y|X] + bE[Z|X]$

Propriedade 4 (Tirar o que é Conhecido (Taking out what is known)). Se g é uma função, $g(X)$ é "conhecido" dado X :

$$E[g(X) \cdot Y|X] = g(X) \cdot E[Y|X]$$

Propriedade 5 (Independência - Q11). Se X e Y são independentes ($X \perp Y$), então $E[Y|X] = E[Y]$ (constante). A informação sobre X não altera a esperança de Y .

Propriedade 6 (Idempotência (Lei da Torre)). $E[E[Y|X]|X] = E[Y|X]$ (A melhor estimativa da melhor estimativa é a própria melhor estimativa).

Propriedade 7 (Projeção L^2 - Q22). $E[Y|X]$ é a "melhor" aproximação de Y que pode ser feita usando apenas X , no sentido de que minimiza a variância do erro (Mínimos Quadrados):

$$E[Y|X] = \arg \min_{g(X)} E[(Y - g(X))^2]$$

O erro $W = Y - E[Y|X]$ é **ortogonal** a qualquer função de X :

$$E[W \cdot g(X)] = 0 \implies \text{Cov}(\mathbf{X}, \mathbf{Y} - \mathbf{E}[\mathbf{Y}|\mathbf{X}]) = \mathbf{0}$$

(Isto prova a Q22).

2.4 Teoremas de Decomposição (As Leis Totais)

Teorema 1 (Lei da Esperança Total - Q19, Q20, Q21, Q24). A esperança da esperança condicional é a esperança original.

$$\mathbf{E}[\mathbf{Y}] = \mathbf{E}[\mathbf{E}[\mathbf{Y}|\mathbf{X}]]$$

Teorema 2 (Lei da Variância Total - Q19, Q20, Q23). A variância total é a soma da esperança da variância condicional e a variância da esperança condicional (Eve's Law: EVVE).

$$\text{Var}(\mathbf{Y}) = \mathbf{E}[\text{Var}(\mathbf{Y}|\mathbf{X})] + \text{Var}[\mathbf{E}[\mathbf{Y}|\mathbf{X}]]$$

Teorema 3 (Lei da Covariância Total - Q27).

$$\text{Cov}(\mathbf{X}, \mathbf{Y}) = \mathbf{E}[\text{Cov}(\mathbf{X}, \mathbf{Y}|\mathbf{Z})] + \text{Cov}[\mathbf{E}(\mathbf{X}|\mathbf{Z}), \mathbf{E}(\mathbf{Y}|\mathbf{Z})]$$

Macete Computacional 4 (Cálculo de Variância via Leis Totais - Q20). Para calcular $\text{Var}(Y)$ usando a Lei Total (LTV):

1. Calcule $g(X) = E[Y|X]$.
2. Calcule $h(X) = \text{Var}(Y|X)$.
3. Calcule $\text{Var}(Y) = E[h(X)] + \text{Var}[g(X)]$.

Frequentemente, é mais fácil calcular $\text{Var}(Y)$ usando $E[Y^2] - (E[Y])^2$:

- $E[Y] = E[E[Y|X]]$ (usando a LTE).
- $E[Y^2] = E[E[Y^2|X]]$ (usando a LTE na v.a. Y^2).
- **Truque:** $E[Y^2|X] = \text{Var}(Y|X) + (E[Y|X])^2 = h(X) + [g(X)]^2$.
- Combine tudo: $\text{Var}(Y) = E[h(X) + g(X)^2] - (E[g(X)])^2$.

2.5 Modelos Conjugados e Casos Notáveis da Lista

- **Poisson-Binomial (Q12, Q13):** Se $Y \sim \text{Poisson}(\lambda)$ (nº de passas total) e $X|Y = n \sim \text{Bin}(n, p)$ (nº de passas que você recebe), então a marginal de X é:

$$X \sim \text{Poisson}(\lambda p)$$

(Intuitivo: "afinamento" (thinning) de um processo de Poisson).

- **Binomial-Binomial (Q14):** Se $X \sim \text{Bin}(m, p)$, $Y \sim \text{Bin}(n, p)$, $S = X + Y$. Então $S \sim \text{Bin}(m + n, p)$. A condicional é:

$$X|S = k \sim \text{Hipergeométrica}(N = m + n, K = m, n = k)$$

Portanto, $E[X|S = k] = k \cdot \frac{m}{m+n} \implies E[X|S] = S \cdot \frac{m}{m+n}$.

- **Geométrica-Geométrica (Q16):** Se $X_1, X_2 \sim \text{Geom}(p)$ (i.i.d.), $S = X_1 + X_2$. Então $S \sim \text{Binomial Negativa}(r = 2, p)$. A condicional é:

$$X_1|S = k \sim \text{Uniforme Discreta}\{0, 1, \dots, k\}$$

(A probabilidade é $1/(k + 1)$ para cada ponto).